

2

Sicherstellen der Datenqualität

Teil 2 der Abschlussprüfung

Allgemeine Korrekturhinweise

Die Lösungs- und Bewertungshinweise zu den einzelnen Handlungsschritten sind als Korrekturhilfen zu verstehen und erheben nicht in jedem Fall Anspruch auf Vollständigkeit und Ausschließlichkeit. Neben hier beispielhaft angeführten Lösungsmöglichkeiten sind auch andere sach- und fachgerechte Lösungsalternativen bzw. Darstellungsformen mit der vorgesehenen Punktzahl zu bewerten. Der Bewertungsspielraum des Korrektors (z. B. hinsichtlich der Berücksichtigung regionaler oder branchenspezifischer Gegebenheiten) bleibt unberührt.


Zu beachten ist die unterschiedliche Dimension der Aufgabenstellung (nennen – erklären – beschreiben – erläutern usw.).

Für die Bewertung gilt folgender Punkte-Noten-Schlüssel:

Note 1	=	100 – 92 Punkte	Note 2	=	unter	92 – 81 Punkte	
Note 3	=	unter	81 – 67 Punkte	Note 4	=	unter	67 – 50 Punkte
Note 5	=	unter	50 – 30 Punkte	Note 6	=	unter	30 – 0 Punkte

1. Aufgabe (27 Punkte)

- a) 7 Punkte, pro Datenpunkt 0,7 Punkte, insgesamt 10 Datenpunkte (hier als Rauten dargestellt), zwei Datenpunkte sind bereits vorgegeben (Kreise)



- b) 3 Punkte

Siehe Lösungsskizze. 1 Punkt für Schnittpunkt mit der Ordinate bei -50, 1 Punkt für Ermittlung eines weiteren Punktes über die Steigung, 1 Punkt für das Einzeichnen einer Geraden.

c) 5 Punkte

1 Punkt: gegebene Gerade wird verlängert bis Schnittpunkt zur Ordinate und $\beta_0 = -200$ wird abgelesen

1 Punkt: Steigungsdreieck wird eingezeichnet

1 Punkt: ΔA wird abgelesen

1 Punkt: ΔT wird abgelesen

1 Punkt: $\beta_1 = \Delta A / \Delta T$ wird berechnet

Achsenabschnitt β_0 : Die Regressionsgerade so verlängern, bis sich ein Schnittpunkt mit der Ordinate ergibt (gestrichelt in der Lösung) und Schnittpunkt ablesen: $\beta_0 = -200$

Steigungsmaß β_1 : Hierzu ein möglichst großes Steigungsdreieck einzeichnen, ΔA , ΔT ablesen und aus diesen das Steigungsmaß berechnen (siehe Lösungszeichnung):

$$\beta_1 = \Delta A / \Delta T = 350 - (-200) / 30 = 550 / 30 = 18.33$$

Andere Ergebnisse wegen Zeichnungsungenauigkeiten möglich. Die Ergebnisse sollten aber mit der Graden stimmig sind. Es ist hier nicht als Fehler zu werden, wenn die Einheit für β_1 1/°C fehlt

da) 3 Punkte

$$T_{\text{regression}}(28^\circ\text{C}) = 10 * 28 - 50 = \underline{230}$$

db) 3 Punkte

$$T_{\text{grafisch}}(28^\circ\text{C}) = 18.33 * 28 - 200 = 313.24$$

$$\text{Wenn c) nicht gelöst werden konnte: } T_{\text{grafisch}}(28^\circ\text{C}) = 15 * 28 - 150 = 270$$

dc) 3 Punkte

Die Daten sind nicht über den betrachteten Bereich linear, sondern nur abschnittsweise linear. Dadurch beeinflussen Datenpunkte für kleine Temperaturen, wo der Absatz näherungsweise 0, und hohe Temperaturen, wo der Absatz stagniert bei ca. 380 Eiskugeln/Tag liegt, den Verlauf und die ermittelte Gerade hat einen flacheren Verlauf, wodurch die beobachtete Unterschätzung in diesem Bereich entsteht.

Ursache könnte ein nicht gut geeignetes Modell (Lineare Regression) oder eine deutlich zu geringe Anzahl von Datenpunkten sein.

dd) 3 Punkte

Ein Lösungsvorschlag wird erwartet.

Mögliche Lösungsvorschläge:

- Filterung auf den kritischen Temperaturbereich
- Höhere Gewichtung der Punkte im kritischen Temperaturbereich
- Berücksichtigung von mehr Datenpunkten und laufende Kontrolle über den Korrelationskoeffizienten r der Linearen Regression, ob dieser sich verbessert.
- Verwendung eines anderen ML-Modells, zum Beispiel
 - Entscheidungsbäume können verwendet werden, um die Daten in verschiedene Regionen aufzuteilen und für jede Region ein separates Modell zu erstellen. Da die Struktur des Baumes dynamisch an die Daten angepasst wird, eignet er sich gut für abschnittsweise lineare Beziehungen.
 - Verwendung von Ensemble-Methoden wie Random Forests. Diese Methoden können komplexe, nicht-lineare Beziehungen modellieren und sind oft in der Lage, abschnittsweise lineare Verläufe gut zu approximieren.
- Berücksichtigung weiterer Features wie Ferienzeiten, Altersklasse, Regenwahrscheinlichkeit, standortabhängige Einflüsse, Preis, Verkäufer/Eiswagen, begleitende Marketingmaßnahmen.

Andere Antworten sind möglich.

2. Aufgabe (25 Punkte)

- a) 4 Punkte (2 Punkte je Beschreibung)

Für ein **Data Warehouse** werden die Daten aus einem Data Lake mithilfe eines ETL-Prozesses in ein bestimmtes Schema gebracht.

Ein **Data Lake** ist ein System, in dem eine große Menge von zumeist nicht-normalisierten Daten aus verschiedenen Quellen abgelegt wird.


- b) 5 Punkte

```
CREATE TABLE Transaktion (  
    Transaktions_ID INT PRIMARY KEY,  
    Datum DATE,  
    Uhrzeit TIME,  
    Kunden_ID INT,  
    Becher_ID INT,  
    Preis DECIMAL(2),  
    Service_ID INT,  
    Tisch_ID INT);
```

- c) 2 Punkte

Dimensionstabellen sind mit Faktentabellen üblicherweise in 1:N Beziehungen verbunden (1:1 auch möglich).

- d) 8 Punkte



Auch das Datum kann als Dimension modelliert werden. Andere Notationsformen sind gültig.

- ea) 4 Punkte

Erwartet werden Antworten wie zum Beispiel:

Änderung von Business Keys kann vorkommen; hoher Ressourcenverbrauch bei der Anpassung, vor allem wegen historischer Daten; Surrogate Key dient als Puffer zwischen warehouse und operations

- eb) 2 Punkte

Business Keys werden nur in den Dimensionstabellen gespeichert.

3. Aufgabe (27 Punkte)

a) 3 Punkte

```
UPDATE SpeiseGetränk          1P
SET PreisAktuell = PreisAktuell * 1.05;    2P
```

b) 7 Punkte

```
SELECT k.*, BestellNr          1P
FROM Kunde k INNER JOIN Bestellung b
    ON k.Kd_TelefonNr = b.Kunde
    INNER JOIN Kurier c ON b.CourierID = c.CourierID    2P
WHERE MONTH(BestellDatum) = 11 AND YEAR(BestellDatum) = 2025    4P
    AND c.Kd_Vorname = "David" AND c.Kd_Nachname = "Scholz"
```

c) 9 Punkte

```
SELECT k.Kd_TelefonNr, Kd_Vorname, Kd_Nachname,
    COUNT(*) AS "Anzahl Bestellungen"    3P
FROM Kunde k INNER JOIN Bestellung b
    ON k.Kd_TelefonNr = b.Kunde    2P
GROUP BY Kd_TelefonNr    1P
HAVING COUNT(*) >2    2P
ORDER BY Kd_Nachname, Kd_Vorname;    1P
= 9P
```

d) 8 Punkte

```
Erwartet wird:
SELECT Kd_Vorname, Kd_Nachname,          1P
    AVG( b.LieferUhrzeit - b.UebergabeKurierZeit)
    AS "Durchschnittliche Lieferdauer"    3P
FROM bestellung b JOIN Kurier c ON b.CourierID=c.CourierID    1P
GROUP BY c.CourierID    2P
ORDER BY c.Nachname    1P
```

Anmerkung: In MariaDB ist eine Formatierung der Zeit für die Ausgabe notwendig. Das wird aber nicht erwartet. Wesentlich für die Bewertung ist die Logik. Im Folgendem das Statement für MariaDB

```
SELECT Vorname, Nachname,
    SEC_TO_TIME( AVG(TIME_TO_SEC(b.LieferUhrzeit) - TIME_TO_SEC( b.UebergabeKurier-
    Zeit)))
    AS "Durchschnittliche Lieferdauer"
FROM bestellung b JOIN Kurier c ON b.CourierID=c.CourierID
GROUP BY c.CourierID
ORDER BY c.Nachname
```

4. Aufgabe (21 Punkte)

a) 3 Punkte

API: Application Programming Interface

Eine API (Application Programming Interface) ist eine Schnittstelle, die es verschiedenen Softwareanwendungen ermöglicht, miteinander zu kommunizieren.

b) 4 Punkte

Eine 2FA besteht aus zwei unterschiedlichen Faktoren aus den Bereichen Besitz, Wissen und Inhärenz biometrische Merkmale). Zwei der Bereiche müssen genannt werden.

Vorteile:

- Ein gestohlenes/weitergegebenes Passwort reicht nicht aus, um an den API-Key zu kommen.
- Geringere Abhängigkeit von Passwort-Qualität.
- Einfachere Detektierung von Angriffsversuchen, z. B. durch unbefugte Anmeldeversuche

Weitere sinnvolle Antworten sind möglich.

c) 4 Punkte

- **Zugangskontrolle:** Verschlüsselungen, Mehr-Faktor-Authentifizierungen, strenge Passwortverfahren erfolgen.
- **Zugriffskontrolle:** Berechtigungskonzepte
- **Weitergabekontrolle:** Verschlüsselungen, Berechtigungen

d) 10 Punkte

- Reservierungen sollten auch nur nach Login aufrufbar sein.
- Passwörter nicht zurückgeben/oder verschlüsseln.
- Intern werden die Daten nicht verschlüsselt (SSL).
- Über Reservierungen sind alle Telefonnummern des Kunden verfügbar.
- Customer müssen die Möglichkeit haben, ihre Daten zu ändern (PUT hinzufügen).
- Nicht mehr benötigte Daten, wie von der Registrierung oder Customer, sollen automatisch gelöscht werden.
- Nicht jeder sollte Food löschen können.
- u. a.

